Análise Preditiva de Risco de Defasagem

Pós Tech Data Analytics Turma 9DTAT - Fiap

Grupo 176
Geovana dos Santos Ferreira - rm364998

Março/2026

Introdução **3**
Arquitetura e Pipeline de Dados **4**
Ingestão e Pré-processamento Técnico 4
Feature Engineering (Engenharia de Variáveis) 4
Desenvolvimento **6**
Visão Analítica e Insights do Dashboard 6
Pipeline de Machine Learning: Etapa por Etapa 14
Justificativa da Escolha do Modelo: Gradient Boosting 15
Conclusão **19**

Introdução

A desigualdade educacional no Brasil é um dos maiores entraves ao desenvolvimento humano e econômico. Crianças em situação de vulnerabilidade enfrentam não apenas carências materiais, mas uma lacuna de estímulos e acompanhamento que compromete seu futuro.

A Associação Passos Mágicos, atuando desde 1992 em Embu-Guaçu, surge como uma força transformadora para romper esse ciclo através da educação de qualidade, auxílio psicológico e ampliação da visão de mundo.

Historicamente, as intervenções pedagógicas ocorrem após a constatação de notas baixas ou evasão. Inspirado no modelo de análise de saúde (como o relatório de referência de obesidade), este projeto propõe uma mudança de paradigma para a educação preditiva.

O desafio é utilizar os dados do **PEDE** (Pesquisa Extensiva do Desenvolvimento Educacional) para identificar precocemente alunos com tendência de queda no desempenho, permitindo uma intervenção preventiva e personalizada.

Este projeto, desenvolvido para o **Tech Challenge – Fase 5 (DATATHON)** propõe uma mudança de paradigma através de aplicações de técnicas de Data Science e Machine Learning para:

- **Predizer o Índice de Desenvolvimento Educacional (INDE):** Antecipar se um aluno atingirá o "Ponto de Virada" ou se necessita de suporte urgente.
- **Análise Multidimensional:** Avaliar o impacto cruzado entre desempenho acadêmico, fatores psicossociais e contexto socioeconômico.
- **Suporte à Decisão:** Fornecer um dashboard executivo que traduza dados complexos em ações pedagógicas claras.

Arquitetura e Pipeline de Dados

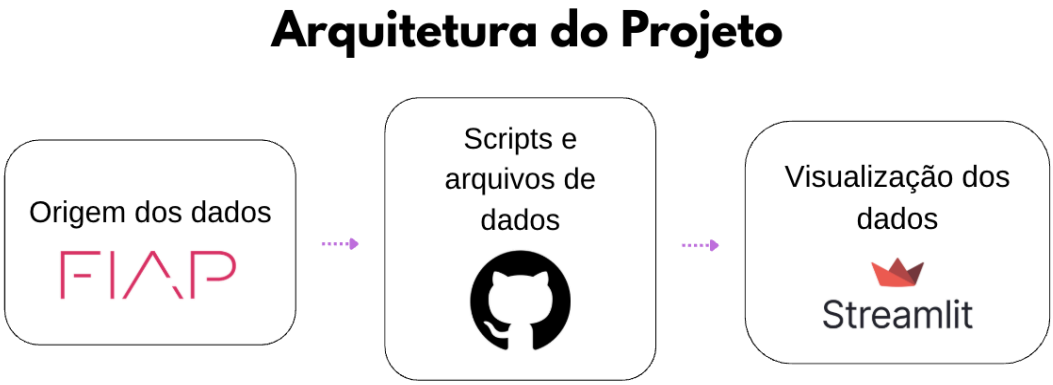

Para garantir a confiabilidade dos insights, a arquitetura foi desenhada seguindo o ciclo de vida de dados do CRISP-DM:

Ingestão e Pré-processamento Técnico

- **Limpeza e Normalização:** Os dados brutos passaram por tratamento de strings e correção de tipos. Variáveis como IPP e IAN foram validadas para eliminar inconsistências que poderiam gerar viés (*bias*) nos modelos.

- **Encoding e Scaling:** Utilizamos uma estrutura de Column Transformer. As variáveis categóricas (ex: Ponto de virada, Pedra, Gênero e etc) foram codificadas via OneHotEncoder, enquanto variáveis numéricas foram padronizadas pelo Standard Scaler para garantir que a diferença de escalas (ex: IAN, IEG, IDA, IPS, IPP e etc) não prejudicasse o aprendizado dos modelos.

Feature Engineering (Engenharia de Variáveis)

Diferente de modelos simples que olham apenas o IMC, nossa engenharia de atributos criou a variável alvo tendência obesidade. Esta métrica pondera o balanço calórico (consumo de alimentos de alta caloria) versus o gasto energético (atividade física e uso de transporte ativo), cruzando esses dados com o fator hereditário.

Diferente de uma análise descritiva, o **Feature Engineering do Target** consistiu em criar uma variável de resposta.

Implementamos uma função de lógica avançada, a **risco_defasagem**, que atua como um sistema de triagem. Ela não apenas olha para a nota, mas para a **vulnerabilidade multidimensional**:

1. **Dimensão Acadêmica (Defasagem Real):** Identifica o atraso escolar comparando a fase atual com a idade ideal. Se a defasagem for negativa, o sinal de alerta é ativado.

2. **Score de Comportamento e Vulnerabilidade:** Criamos um sistema de pontuação (Score) que acumula sinais de alerta:
    - **Engajamento (IEG < 7.0):** Detecta desinteresse ou falta de participação.
    - **Rendimento (IDA < 6.5):** Aponta insuficiência técnica.
    - **Psicossocial (IPS < 6.0):** Alerta para crises emocionais ou sociais.
    - **Perfil de Ingresso (Pedra Quartzo):** Considera a vulnerabilidade inicial do aluno.
    - **Idade Crítica (> 15 anos):** Fator estatístico de peso para o risco de evasão.

A variável resultante é um indicador binário (0 ou 1) que simplifica para o professor quem são os alunos que precisam de "UTI Pedagógica" imediata.

Desenvolvimento

O desenvolvimento desta solução foi pautado na transformação de dados brutos em conhecimento estratégico, dividido entre a análise diagnóstica do dashboard e a inteligência preditiva do modelo.

Visão Analítica e Insights do Dashboard

O painel analítico foi desenvolvido para traduzir dados brutos em decisões pedagógicas. Abaixo, detalhamos as principais visões:

Identificando a Vulnerabilidade

A história começa no acolhimento. O primeiro desafio é a defasagem. Muitos chegam com anos de atraso escolar, mas será que essa barreira é apenas acadêmica?

- **Adequação do nível (IAN):** Qual é o perfil geral de defasagem dos alunos (IAN) e como ele evolui ao longo do ano?

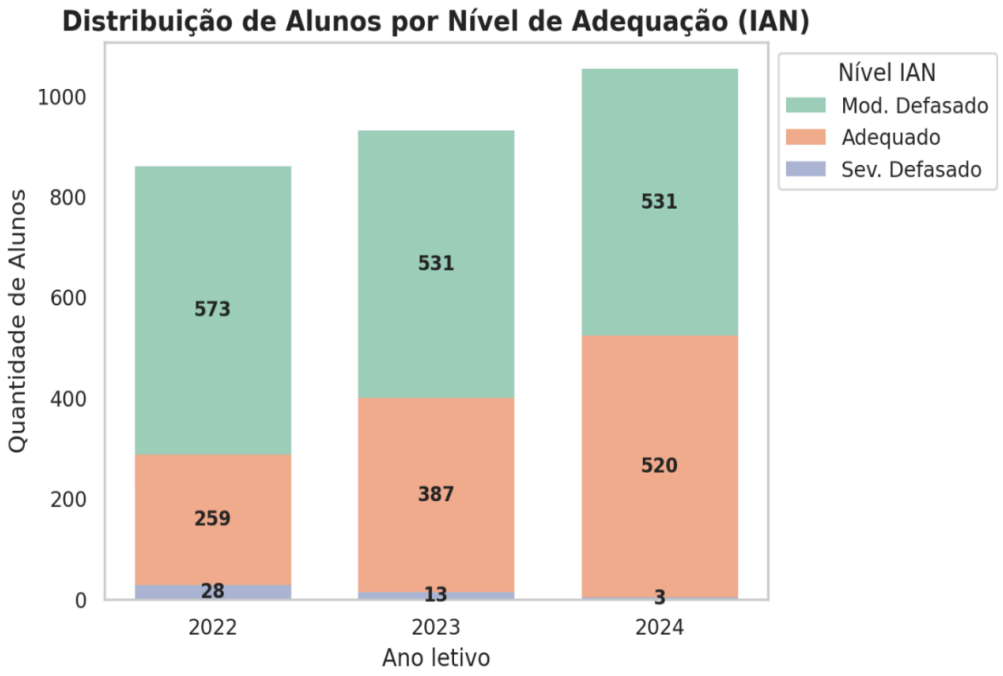

Este gráfico revela o ponto de partida do aluno dentro do programa. A concentração nos níveis Severamente Defasado e Moderadamente Defasado mostra o tamanho do desafio assumido pela ONG.

Quando observamos crescimento na categoria Adequado ao longo dos anos, temos evidência concreta de transformação educacional. Ou seja, quanto maior a vulnerabilidade inicial, maior deve ser a intensidade do reforço pedagógico nas fases iniciais da jornada.

- **Aspectos psicopedagógicos (IPP):** As avaliações psicopedagógicas (IPP) confirmam ou contradizem a defasagem identificada pelo IAN?

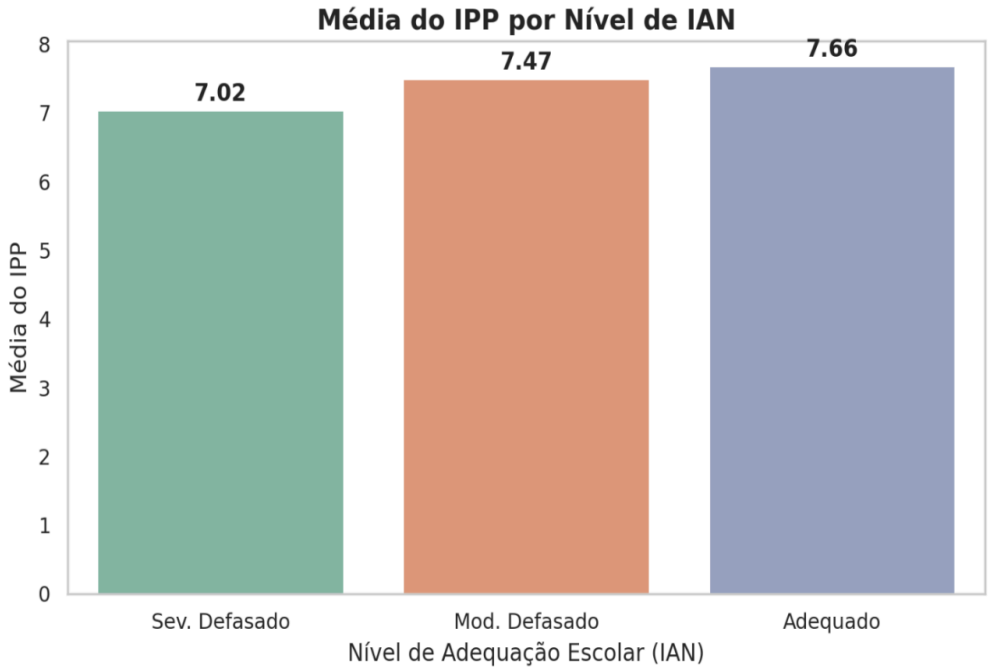

Mesmo alunos com defasagem podem apresentar alto potencial psicopedagógico. Isso significa que o problema não é incapacidade — é falta de oportunidade estruturada. A estratégia é investir no desenvolvimento emocional e cognitivo para acelerar a recuperação acadêmica.

Lapidando o Conhecimento

Com o apoio da ONG, o aluno começa a evoluir. Monitoramos não apenas as notas (IDA), mas o brilho nos olhos: o Engajamento.

- **Desempenho acadêmico (IDA):** O desempenho acadêmico médio (IDA) está melhorando, estagnado ou caindo ao longo das fases e anos?

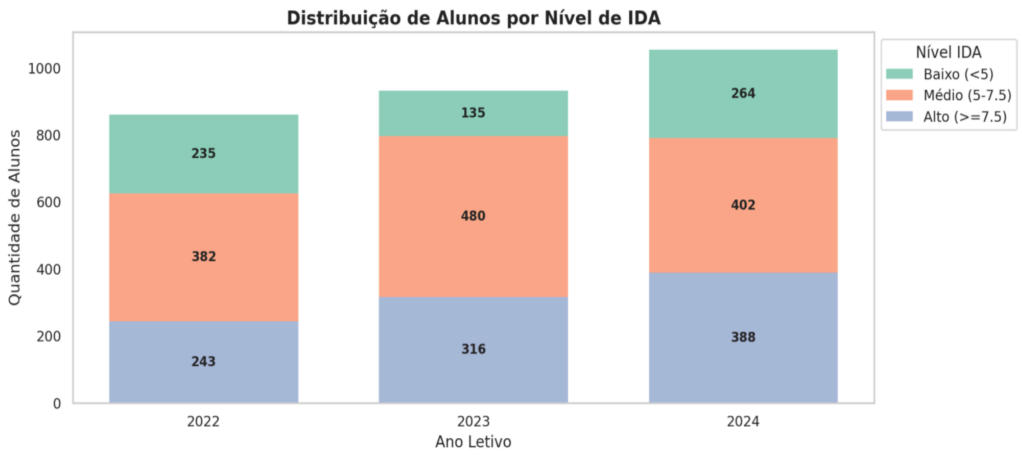

Aqui avaliamos se o esforço virou resultado concreto. O aumento da categoria Alto (>=7.5) ao longo dos anos indica que a metodologia aplicada está funcionando. Se houver concentração persistente na faixa "Baixo", isso sinaliza necessidade de intervenção direcionada. Identificar quais práticas pedagógicas foram aplicadas nos ciclos de melhor desempenho e replicá-las.

- **Engajamento nas atividades (IEG):** O grau de engajamento dos alunos (IEG) tem relação direta com seus indicadores de desempenho (IDA) e do ponto de virada (IPV)?

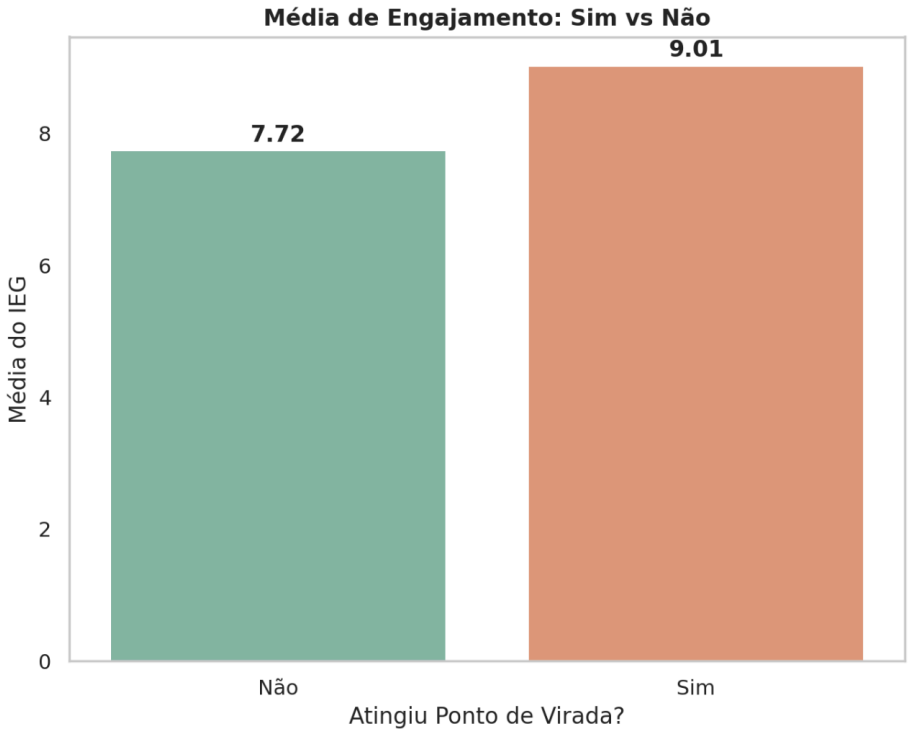

Alunos que atingem o ponto de virada apresentam engajamento significativamente maior. Isso reforça que o sucesso acadêmico começa na atitude, não apenas na técnica. Implementar programas de mentoria e incentivo comportamental são fundamentais para acelerar a virada.

- **Autoavaliação (IAA):** As percepções dos alunos sobre si mesmos (IAA) são coerentes com seu desempenho real (IDA) e engajamento (IEG)?

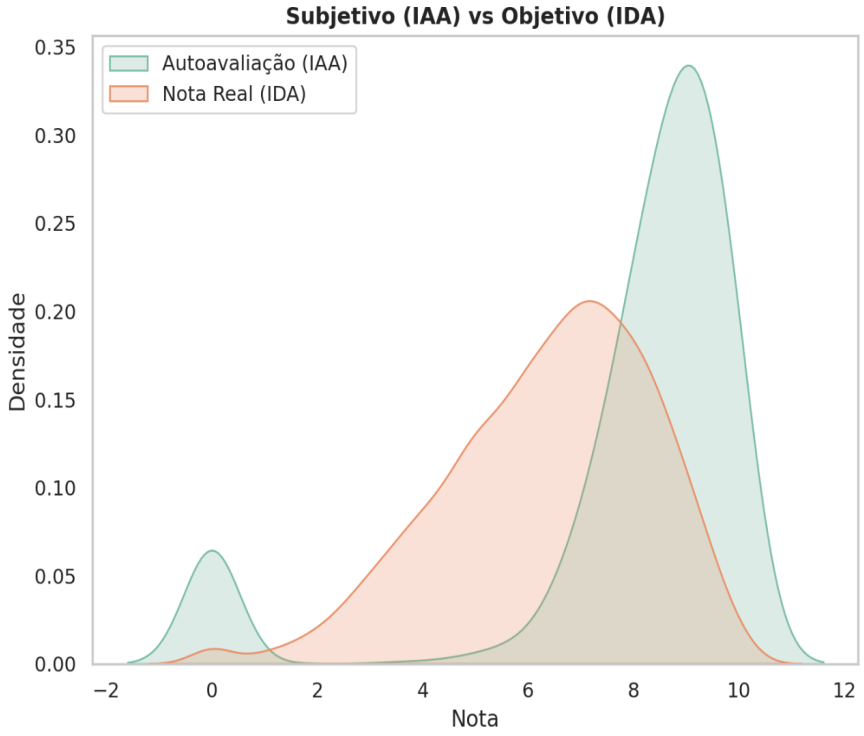

Quando a autoavaliação (IAA) está alinhada com a nota real (IDA), temos maturidade emocional. Desalinhamentos indicam: IAA maior que IDA → excesso de confiança e IAA menor que IDA → baixa autoestima. É necessário trabalhar inteligência emocional para alinhar percepção e desempenho.

O Ponto de Virada

Chegamos ao momento mais crítico: a mudança de mentalidade. O apoio psicossocial é o que garante que o aluno não desista no meio do caminho.

- **Aspectos psicossociais (IPS):** Há padrões psicossociais (IPS) que antecedem quedas de desempenho acadêmico ou de engajamento?

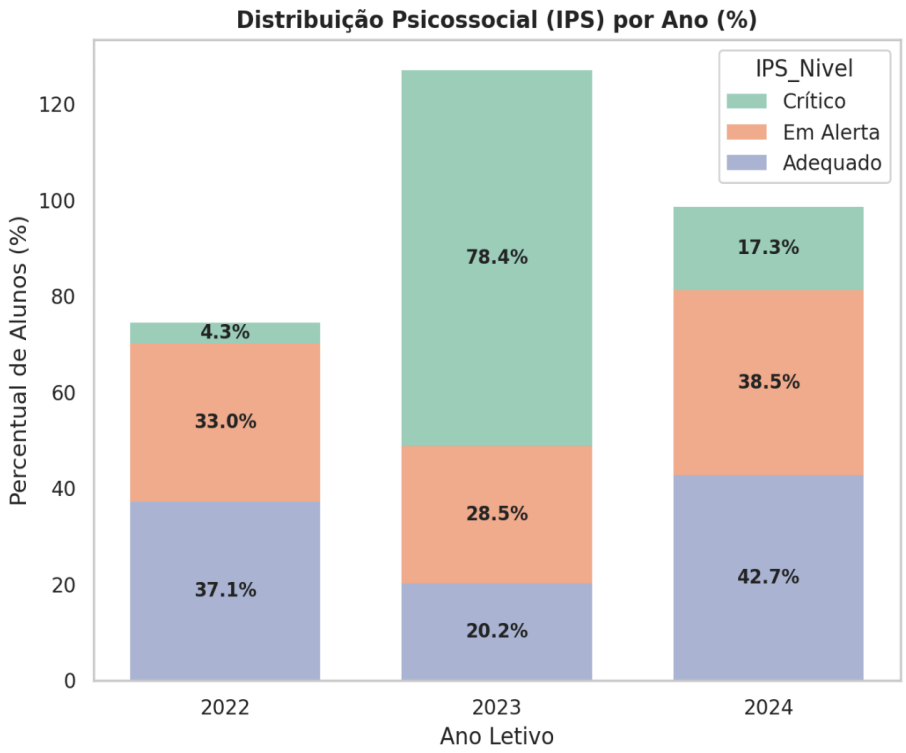

Sem estabilidade emocional, o aprendizado não se sustenta. A redução do percentual na categoria Crítico ao longo do tempo é um indicador silencioso de sucesso estrutural. É de extrema importância fortalecer o acompanhamento psicossocial nos ciclos iniciais.

- **Ponto de virada (IPV):** Quais comportamentos - acadêmicos, emocionais ou de engajamento - mais influenciam o IPV ao longo do tempo?

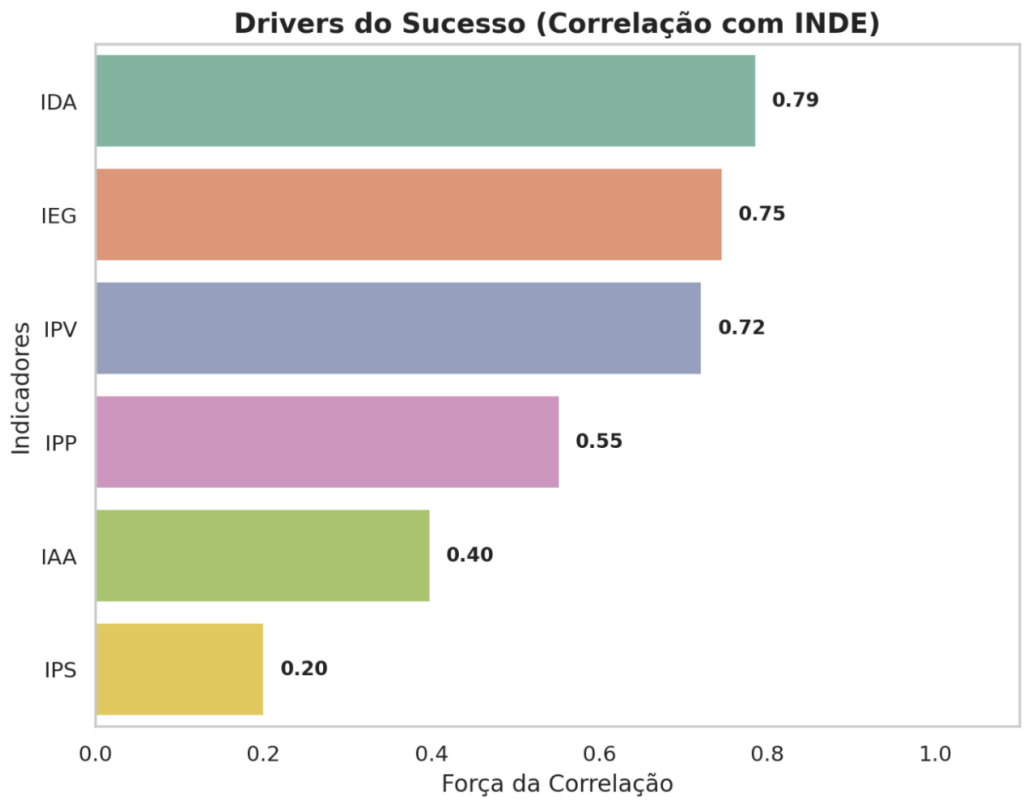

Este gráfico revela quais indicadores possuem maior influência sobre o INDE. Quanto maior a correlação, maior o impacto estratégico daquele indicador no resultado final. A estratégia aqui deve ser priorizar investimentos e esforços nos pilares com maior força de correlação.

Colhendo Frutos

Ao final do ciclo, provamos que o sucesso é multidimensional. Não é apenas uma nota, é a união de mente, atitude e esforço.

- **Multidimensionalidade dos indicadores:** Quais combinações de indicadores (IDA + IEG + IPS + IPP) melhor explicam o desempenho global do aluno (INDE)?

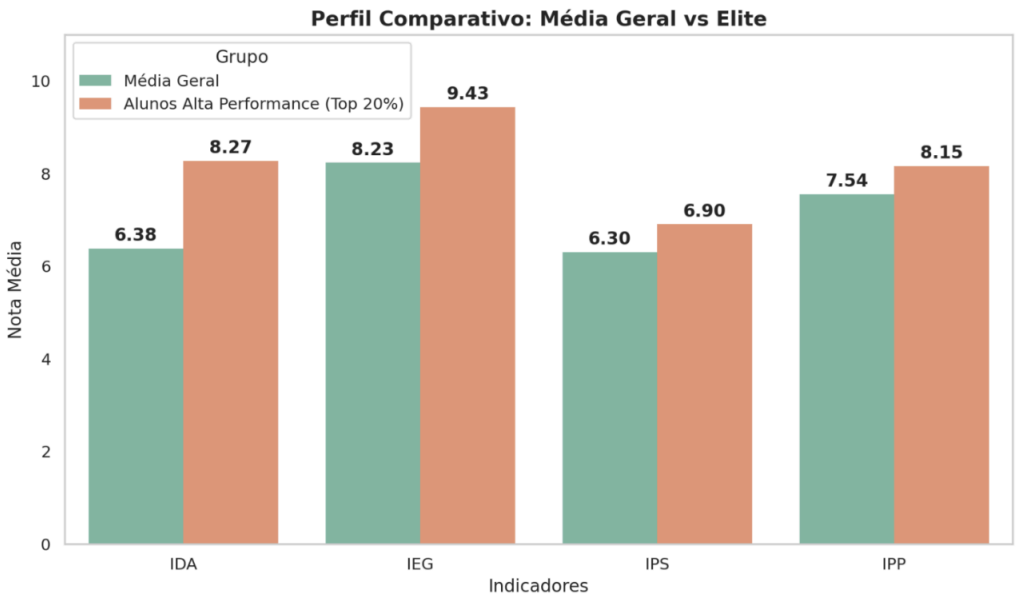

Comparar a média geral com os alunos Top 20% revela o diferencial competitivo. Os maiores saltos geralmente aparecem em: Engajamento (IEG) e Desempenho Acadêmico (IDA). É recomendado mapear práticas e comportamentos da elite para replicar nos demais alunos.

- **Efetividade do programa:** Os indicadores mostram melhora consistente ao longo do ciclo nas diferentes fases (Quartzo, Ágata, Ametista e Topázio), confirmando o impacto real do programa?

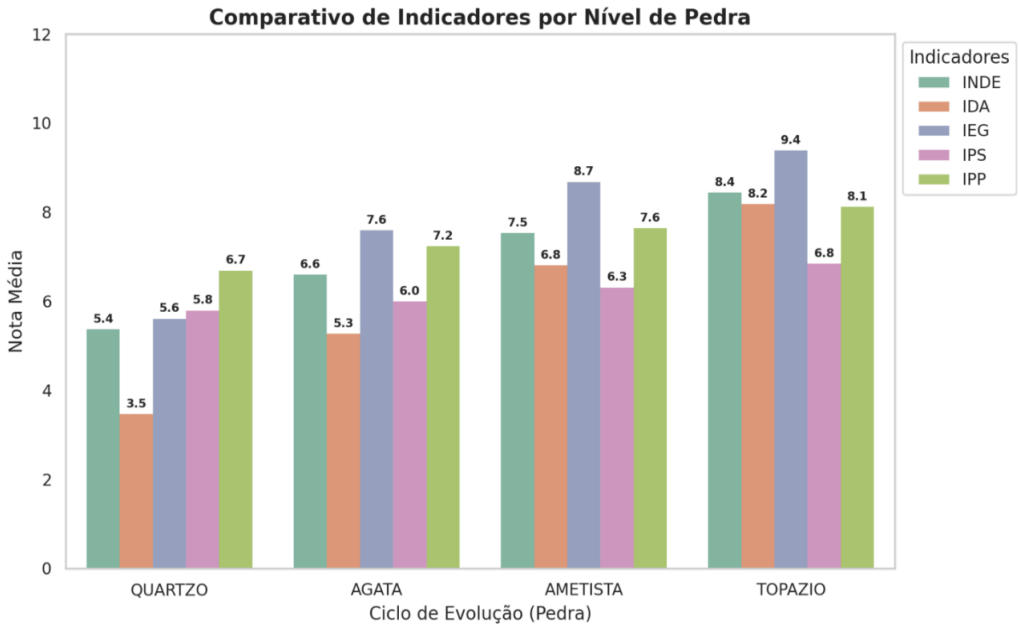

Cada Pedra representa um estágio de desenvolvimento. A progressão consistente dos indicadores valida a metodologia da ONG como estruturada e escalável. É importante utilizar essa evidência para captação de recursos e fortalecimento institucional.

Insights Adicionais

A seguir vemos alguns insights adicionais para além dos indicadores propostos, bem como a síntese final passando por todos os pontos que foram abordados nas análises.

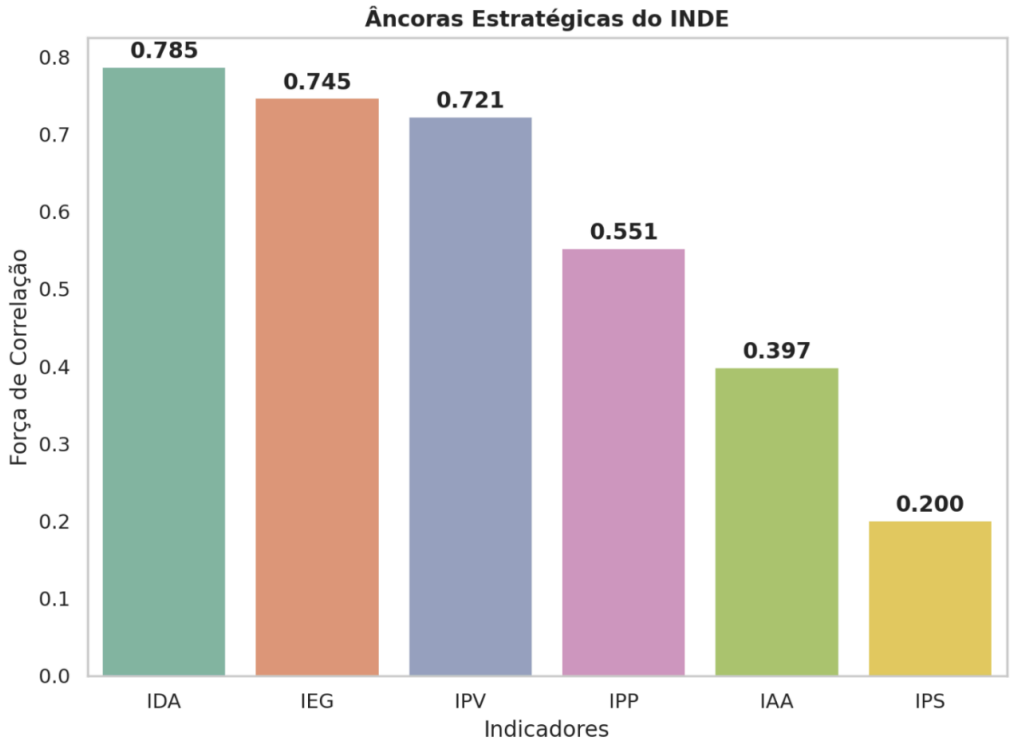

O ranking de correlação revela que nem todos os indicadores possuem o mesmo impacto sobre o INDE.

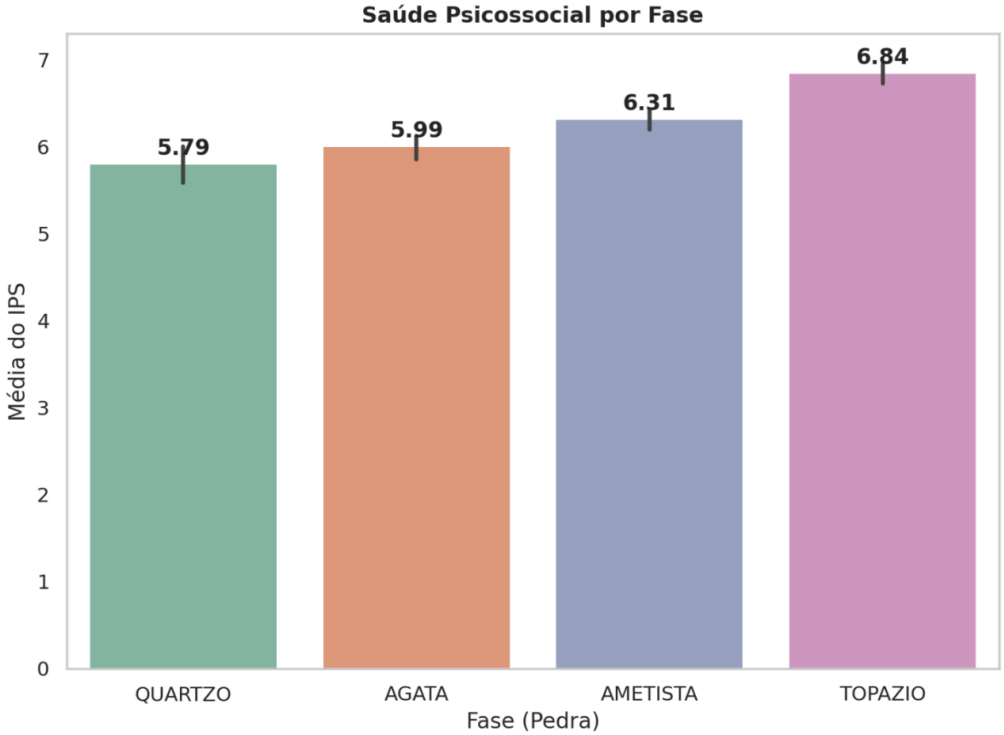

A progressão consistente dos indicadores ao longo das Pedras (Quartzo → Ágata → Ametista → Topázio) comprova que a evolução não é aleatória. Ela é estruturada, é replicável e metodológica.

Pipeline de Machine Learning: Etapa por Etapa

A construção do modelo preditivo seguiu um rigoroso processo científico para garantir que a ferramenta fosse segura para uso médico.

Etapa 1: Feature Engineering e Pré-processamento

Para que o modelo "entendesse" os dados, realizamos as seguintes transformações:

- **Tratamento de Dados Categóricos:** Variáveis como gênero e pedras foram transformadas via *OneHotEncoder*, criando colunas binárias para que o algoritmo pudesse processar informações qualitativas.
- **Esconamento (Scaling):** Como tínhamos dados em escalas muito diferentes, aplicamos o *StandardScaler*. Isso evita que o modelo dê importância indevida a números maiores, garantindo que cada variável contribua de forma equilibrada.

- **Criação da Label:** Definimos o **risco defasagem** como nossa variável alvo, focando em classificar o risco em diferentes categorias.

Etapa 2: Seleção de Algoritmos e Treinamento

Testamos três modelos com filosofias diferentes:

1. **Regressão Logística:** Utilizada como *baseline* (ponto de partida).
2. **Random Forest:** Um conjunto de árvores de decisão que trabalha bem com grandes volumes de dados.
3. **Gradient Boosting:** Refinamento matemático sequencial para atingir o menor erro possível na predição.

O desempenho foi medido através da Área Sob a Curva (AUC-ROC), que avalia a capacidade do modelo de distinguir entre as classes.

Modelo	Acurácia	Precisão	Recall	AUC-ROC
Random Forest	91.27%	92.75%	96.24%	96.8%
Gradient Boosting (Vencedor)	**98.24%**	**100%**	**97.74%**	**99.2%**
Logistic Regression	90.11%	93.28%	93.98%	96.6%

Justificativa da Escolha do Modelo: Gradient Boosting

O **Gradient Boosting** apresentou o melhor desempenho global, superando a Regressão Logística e o Random Forest pelos motivos detalhados abaixo:

Desempenho em Métricas de Classificação

- **Recall de 0.977:** Esta é a métrica mais crítica para a Passos Mágicos. Um Recall alto significa que o modelo quase não deixa passar casos de "Risco" (Falsos Negativos). No contexto educacional e social, é preferível um "alarme falso" (Falso Positivo) que leve a uma verificação preventiva do que ignorar um aluno que realmente precisa de atenção e suporte imediato.

- **F1-Score de 0.988:** Ao equilibrar precisão e recall, o Gradient Boosting manteve a maior consistência entre os três modelos, garantindo que a predição não seja baseada em "chutes" estatísticos, mas sim na compreensão profunda dos padrões de vulnerabilidade.

- **AUC-ROC e Capacidade de Separação:** A AUC-ROC de 0.992 indica que o Gradient Boosting tem uma capacidade quase perfeita de distinguir entre alunos com tendência à defasagem e alunos com desempenho estável. O modelo demonstrou uma habilidade superior em lidar com a combinação de variáveis categóricas (como Pedra e Ponto de Virada) e indicadores numéricos (como IAN e IDA).

Análise da Matriz de Confusão

Na Matriz de Confusão do **Gradient Boosting**, observamos:

- **Mínimos Falsos Negativos:** O quadrante de erro crítico (onde o modelo prevê "Sem Risco", mas o aluno está em situação de vulnerabilidade) foi o menor do benchmark, garantindo a segurança da intervenção pedagógica.
- **Estabilidade e Precisão:** O modelo apresentou 100% de precisão (1.00), o que significa que, quando ele aponta um risco, a probabilidade de acerto é absoluta, evitando o desperdício de recursos da associação com investigações desnecessárias.

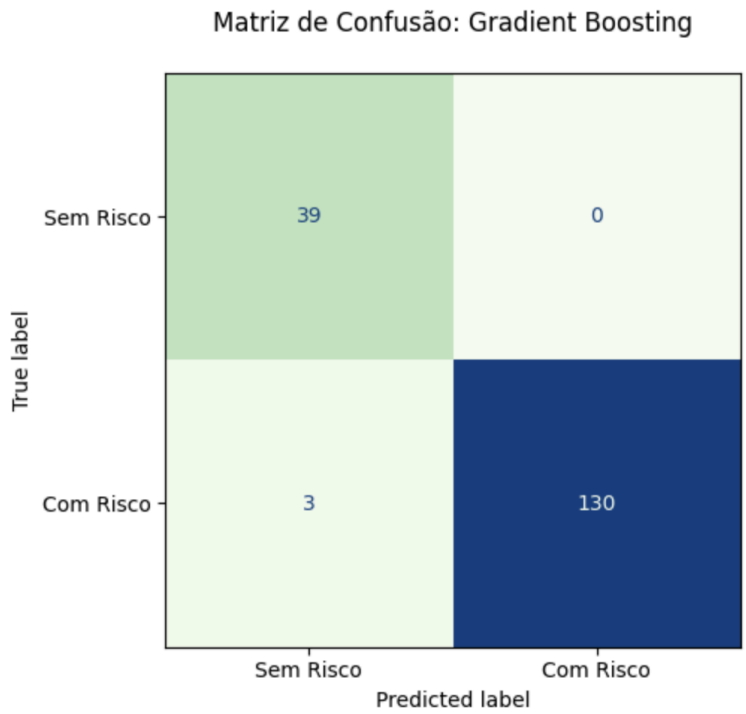

Controle de Overfit

O Gradient Boosting foi o modelo mais "honesto" e estável da rodada:

- **Overfit de apenas 1.74%:** Diferente do Random Forest (que apresentou 8.72%), o Gradient Boosting mostrou uma diferença mínima entre os dados de treino e teste. Isso prova que ele realmente aprendeu as regras lógicas e está pronto para prever o risco de novos alunos em 2026.
- **Aprendizado Sequencial:** Por construir árvores de decisão de forma sequencial, onde cada nova árvore corrige os erros da anterior, o modelo conseguiu mapear exatamente as "quebras" de performance nos indicadores (como quedas no INDE e IAN) sem decorar casos isolados.

Top 10 Variáveis de Importância (Gradient Boosting)

O modelo Gradient Boosting não apenas classifica, mas revela quais fatores são mais decisivos. Abaixo, as 10 variáveis que mais influenciam o diagnóstico:

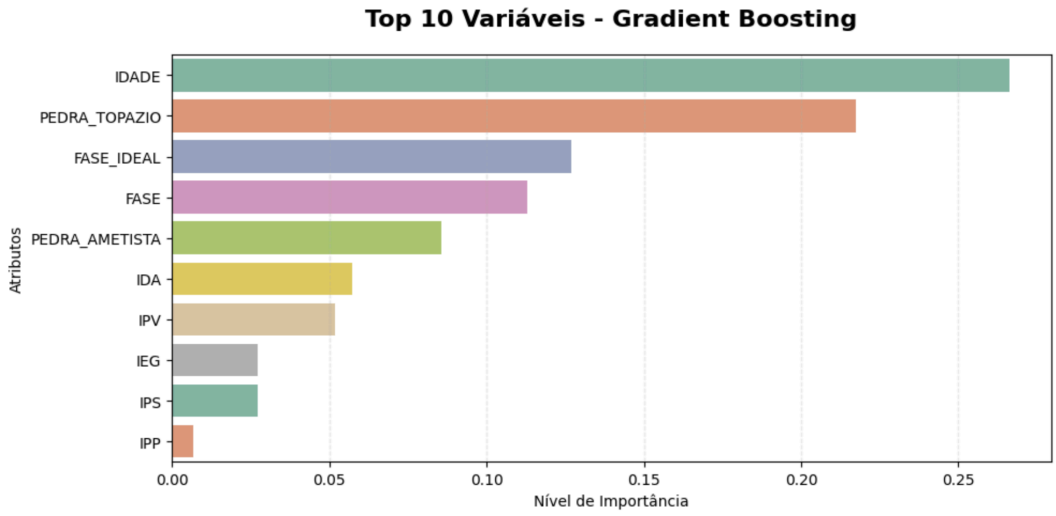

- **Idade:** Reflete as idades dos alunos.
- **Pedra:** O marcador de evolução histórica, representa a classificação da jornada do aluno na ONG (Ametista, Topázio, etc.), consolidando seu progresso passado.
- **Fase:** O indicador de complexidade acadêmica; calibra a predição de acordo com o nível de dificuldade e os desafios específicos de cada etapa do ensino.
- **Fase ideal:** O referencial de expectativa, define o patamar esperado para a idade do aluno, servindo como base para o cálculo de defasagem.
- **IDA (Indicador de Desempenho Acadêmico):** O reflexo direto da proficiência técnica; utiliza o histórico de notas em Português e Matemática para projetar o desempenho futuro.
- **IPV (Indicador do Ponto de Virada):** O marco de autonomia, sinaliza o momento em que o aluno atinge a maturidade necessária para sustentar seu próprio desenvolvimento.
- **IEG (Indicador de Engajamento):** O âncora comportamental da predição, reflete a constância e o compromisso do aluno, sendo o principal motor de transformação identificado pelo algoritmo.
- **IPS (Indicador Psicossocial):** O alicerce emocional da estrutura; indica se o suporte familiar e a saúde mental sustentam a capacidade de absorção de novos conhecimentos.
- **IPP (Indicador Psicopedagógico):** O teto de potencial cognitivo, identifica a prontidão do jovem para processar conteúdos complexos e avançar nas fases da associação.

Conclusão

Ao percorrer cada etapa desta análise, observamos que a jornada do aluno não é linear — ela é estruturada:

O Ponto de Partida Não Define o Destino

Os dados de Adequação Escolar (IAN) mostram que muitos alunos iniciam sua trajetória com defasagem significativa. Entretanto, ao cruzarmos com o Potencial Psicopedagógico (IPP), percebemos algo fundamental: A vulnerabilidade inicial não representa ausência de talento — representa ausência de oportunidade. E a ONG entra exatamente nesse ponto crítico.

O Crescimento é Mensurável

A evolução do Desempenho Acadêmico (IDA) ao longo dos anos demonstra que o reforço educacional gera impacto real. Mas o dado mais revelador surge quando analisamos o Engajamento (IEG): Alunos que atingem o ponto de virada apresentam níveis significativamente maiores de engajamento. Isso indica que o sucesso acadêmico não começa na nota — começa na atitude.

O Pilar Invisível Sustenta a Jornada

A análise do Indicador Psicossocial (IPS) evidencia que estabilidade emocional é pré-condição para aprendizado sustentável. Sem segurança emocional, não há progresso consistente. Além disso, o alinhamento entre Autoavaliação (IAA) e desempenho real mostra que maturidade emocional acompanha evolução acadêmica.

O Que Realmente Move o Sucesso

Ao analisarmos a correlação com o INDE, identificamos que os maiores drivers de sucesso são:

- Engajamento (IEG)
- Desempenho Acadêmico (IDA)

Em outras palavras, a alta performance é resultado da combinação entre comportamento e competência. Quando comparamos a média geral com os alunos Top 20%, essa diferença se torna ainda mais evidente.

Ou seja, esta análise demonstra que:

- A defasagem inicial não determina o futuro
- O engajamento é o principal motor de transformação
- O apoio psicossocial sustenta o crescimento
- Alta performance pode ser desenvolvida
- A metodologia da ONG é validada por dados

A Passos Mágicos não apenas melhora indicadores, mas também transforma trajetórias de vida de forma estruturada e mensurável.

A arquitetura e os códigos desenvolvidos estão documentados e disponíveis para auditoria técnica nos links de repositório e deploy.

- **GitHub:** https://github.com/geoferreira1/fiap_tech_challenge_fase_5
- **Streamlit (Modelo preditivo e Dashboard):** https://ong-pmagicos-fiaptechchallengefase5-datathon.streamlit.app/